محاولتان لتحسين النموذج، وما قِسناه فعلاً

بداية أفضل للمسيّرة، ودمج الأوزان (WiSE-FT)، وقياس حجم الضجيج

0.706	0.182	0.666 / 0.817	±0.02
فئات COCO قبل أي تدريب (AP@0.5)	المسيّرة قبل أي تدريب، عبر صف kite	النموذج المضبوط: COCO / مسيّرة	حجم الضجيج التقريبي في القياس

الخلاصة (وهي ليست خبراً سعيداً كله)

1. **لم نحصل على تحسين مؤكد.** النموذج الجديد (v3) والسابق (v2) لا يمكن التمييز بينهما: فاصل الثقة للفرق يحوي الصفر في فئات COCO وفي المسيّرة.
2. **دمج الأوزان أعطى مقايضة سلسة بين فئات COCO والمسيّرة، وليس مكسباً مجانياً.** ما بدا مكسباً على مجموعة الضبط كان ضجيجاً، واختفى على مجموعة الاختبار.
3. **تصحيح لخطأ ذكرتُه:** قلتُ إن التدريب الأول بدأ بطبقة تصنيف عشوائية. هذا غير صحيح، المكتبة تنسخ صفوف الفئات المتطابقة بالاسم (الفصل 2).

المحتويات

1. المشكلة والفكرتان
2. تصحيح: ما كنتُ أظنه عن الطبقة الأخيرة
3. الفكرة 1: بداية أفضل للمسيّرة
4. الفكرة 2: دمج الأوزان
5. ما هو الضجيج؟ (Bootstrap)
6. التوصية
7. ما قد يحسّن الرقم فعلاً (لم نجرّبه)
8. تحفظات وأسئلة

1. المشكلة والفكرتان

المشكلة: نموذجنا ذو 12 فئة (v2) أقل دقة من YOLO11n الجاهز على فئات COCO بنحو 0.073 (AP@0.5: 0.645 مقابل 0.718). الجاهز لا يعرف المسيّرة. نريد نموذجاً يحتفظ بدقة الجاهز ويضيف المسيّرة.

الفكرة 1: بداية أفضل للفئة الجديدة، وضبط ألطف

في التدريب العادي تبدأ الفئة الجديدة (المسيّرة) من أرقام عشوائية. فكرتي: أنسخ لها صف فئة **مشابهة** من النموذج الجاهز، وهي **الطائرة الورقية (kite)**، لأنها جسم صغير يطير في السماء. وأضبط بمعدل تعلم أقل (0.0002 بدل 0.000625) وعدد جولات أقل (16 بدل 25). السكربت: `scripts/head_surgery.py`.

الفكرة 2: دمج الأوزان (Weight-space ensembling، من ورقة WiSE-FT)

عندنا نموذجان بنفس البنية:

- **A:** قبل الضبط. يعرف فئات COCO جيداً، ويعرف المسيّرة قليلاً.
- **B:** بعد الضبط. يعرف المسيّرة، لكنه نسي جزءاً من COCO.

المعادلة

$$\text{weights} = (1 - \alpha) \times A + \alpha \times B$$

$\alpha = 0$ هو A، و$\alpha = 1$ هو B. النموذج المضبوط يبقى قريباً من نقطة بدايته في فضاء الأوزان، فالنقاط بينهما قد تحتفظ بجزء من الميزتين، **بدون أي تدريب إضافي**. الورقة الأصلية وجدت أن نقطة وسطية تتفوق أحياناً على الطرفين.

السكربت: `scripts/interpolate_models.py`.

2. تصحيح: ما كنتُ أظنه عن الطبقة الأخيرة

> **ما قلتُه سابقاً، وهو خطأ**
>
> بعد قراءة قصيرة لبنية النموذج قلتُ إن التدريب الأول (v2) بدأ بطبقة التصنيف الأخيرة **عشوائية**، وإنه أعاد تعلّم "شخص" و"سيارة" من 4400 صورة، وإن هذا سبب ضعفه أمام الجاهز.

كيف اكتشفتُ الخطأ

1. اختبرتُ ذلك بتحميل الأوزان بنفس الدالة التي تحمّلها المكتبة. النتيجة: `Transferred 493/499` والطبقة الأخيرة **غير** منسوخة. فبدا أن كلامي صحيح.
2. لكن سجل التدريب الفعلي (v2) كان يقول `Transferred 499/499`، ولم يتطابق مع اختباري. فرجعتُ إلى السجل.
3. وجدتُ فيه سطراً قبله: **`Remapped 11/12 cls head rows from pretrained weights by class name`**.

> **الحقيقة**
>
> مدرّب المكتبة (`trainer`) **ينسخ فعلاً صفوف الفئات المتطابقة بالاسم** (11 من 12) قبل التدريب. اختباري تجاوز هذه الخطوة، فاستنتجتُ استنتاجاً خاطئاً. الفئة الوحيدة التي بدأت عشوائية في v2 هي المسيّرة (الفئة 12).

ماذا يعني هذا؟ فكرتي الأولى ليست جديدة بالنسبة للفئات الـ 11: المكتبة تفعلها تلقائياً. الجديد الحقيقي في v3 هو: (أ) صف المسيّرة من kite، (ب) معدل تعلم أقل وجولات أقل. وسبب ضعف v2 أمام الجاهز **ليس** ما قلتُه. السبب الأرجح ما زال النسيان بسبب الضبط على 4400 صورة فقط، وهذا لم يُثبَت.

تعلّمتُ من هذا: لا أكتب تفسيراً سببياً قبل أن أقارنه بالسجل الفعلي.

3. الفكرة 1: بداية أفضل للمسيّرة

أ) قبل أي تدريب (القياس الصفري، Zero-shot)

بنيتُ النموذج بالسكربت (11 فئة منسوخة، والمسيّرة من kite) وقِستُه مباشرة. أولاً تحقّقتُ أنه لا يفسد شيئاً: **كشوفه مطابقة تماماً** للنموذج الجاهز على الفئات الـ 11 في 12 صورة من 12.

- فئات COCO: AP@0.5 = **0.706** (الجاهز بحجم 640 يحصل على 0.718. الفرق ربما بسبب حجم الصورة 512 مقابل 640، ولم أختبر ذلك).
- المسيّرة: AP@0.5 = **0.182** بلا أي تدريب. أي أن صف kite يرى بعض المسيّرات، وليس صفراً.

ب) بعد الضبط (16 جولة، 3.8 ساعة على CPU)

النموذج	COCO AP@0.5	COCO AP@0.5:0.95	مسيّرة AP@0.5	مسيّرة AP@0.5:0.95	المتوسط
قبل الضبط (α = 0، بلا تدريب)	0.706	0.531	0.182	0.101	0.444
التدريب الأول v2 (25 جولة)	0.645	0.455	0.812	0.491	0.729
v3: بعد الضبط (16 جولة)	0.666	0.474	0.817	0.481	0.742
YOLO11n الجاهز (640)	0.718	0.541	-	-	-

قراءة الجدول

- الضبط علّم المسيّرة (0.182 إلى 0.817)، لكنه كلّف فئات COCO حوالي 0.040 (0.706 إلى 0.666). هذا هو ثمن الضبط، ولم تُزِله الفكرة 1.
- الصف الأخير (الجاهز) هو سقف فئات COCO، ولا يعرف المسيّرة.
- الأعمدة الأخيرة (متوسط COCO والمسيّرة) مقياس بسيط أستعمله للمقارنة: يعطي وزناً متساوياً للهدفين.

4. الفكرة 2: دمج الأوزان

بروتوكول الاختبار (تقرّر قبل رؤية النتائج)

- اختيار α على **مجموعة ضبط منفصلة** (197 صورة COCO ليست في الاختبار، و150 صورة مسيّرات جديدة)، وليس على مجموعة الاختبار. اختيار القيمة على الاختبار نفسه ثم الإبلاغ عن نتيجته متفائل، لأن القيمة اختيرت لأنها تبدو جيدة على تلك الصور بالذات.
- **قاعدة الاختيار** (كُتبت قبل التجربة): α الذي يعطي أعلى متوسط لـ (AP@0.5 على فئات COCO، AP@0.5 على المسيّرة) في مجموعة الضبط.
- الشبكة: $\alpha \in \{0, 0.2, 0.4, 0.6, 0.8, 1\}$. والنتيجة تُذكر على مجموعة الاختبار التي لم تُلمَس.

النتائج: مجموعة الضبط مقابل مجموعة الاختبار



AP@0.5 لفئات COCO (أزرق) والمسيّرة (برتقالي) حسب α. اليسار: مجموعة الضبط (انتبه: COCO ارتفع في الوسط). اليمين: مجموعة الاختبار (COCO ينخفض باطّراد).

α	ضبط: COCO	ضبط: مسيّرة	ضبط: متوسط	اختبار: COCO	اختبار: مسيّرة	اختبار: متوسط
0.0	0.735	0.175	0.455	0.706	0.182	0.444
0.2	0.752	0.345	0.548	0.707	0.339	0.523
0.4	0.754	0.548	0.651	0.698	0.525	0.611
0.6	0.765	0.753	0.759	0.692	0.683	0.688
0.8 ★	0.750	0.795	0.772	0.680	0.765	0.723
1.0	0.724	0.816	0.770	0.666	0.817	0.742

★ = القيمة التي اختارتها القاعدة على مجموعة الضبط. COCO = متوسط AP@0.5 على 11 فئة. المتوسط = متوسط (COCO، مسيّرة).

الدرس: ما بدا مكسباً كان ضجيجاً

على مجموعة الضبط ارتفعت دقة COCO عند α = 0.6 إلى 0.765، أعلى من الطرفين (0.735 و0.724)، كما في الورقة الأصلية. القاعدة اختارت **α = 0.8** (متوسط 0.772 مقابل 0.770 عند α = 1). **لكن على مجموعة الاختبار اختفى هذا المكسب:** دقة COCO تنخفض بانتظام من 0.706 إلى 0.666 كلما زاد α، والمسيّرة ترتفع بانتظام. وبالقاعدة نفسها على الاختبار، يتفوق α = 1 (0.742) على α = 0.8 (0.723). مجموعة الضبط صغيرة (197 صورة)، فقفزة 0.03 فيها ضجيج. لو اخترنا α على مجموعة الاختبار لخدعنا أنفسنا.

5. ما هو الضجيج؟ (Bootstrap)

في هذا المشروع قلتُ عدة مرات "الفرق ضمن الضجيج" دون أن أقيسه. هذه المرة قِستُه:

الطريقة

كل نموذج يمرّ مرة واحدة على صور الاختبار. ثم نسحب 100 عيّنة من الصور **مع الإعادة** (بعض الصور مرتين وبعضها لا يظهر)، ونحسب AP@0.5 للنموذجين على نفس العيّنة، وننظر إلى انتشار الفرق. إذا كان الفاصل 95% يحوي الصفر فالفرق قد يكون حظّ اختيار الصور. السكربت: `scripts/bootstrap_compare.py`.

المقارنة	المجموعة	A	B	الفرق (B - A)	فاصل 95%	يحوي الصفر؟
v3 − v2	COCO (صورة 440)	0.645	0.666	+0.020	[-0.001, +0.038]	نعم: لا فرق مؤكد
v3 − v2	مسيّرة (300 صورة)	0.812	0.817	+0.004	[-0.017, +0.030]	نعم: لا فرق مؤكد
v3 − دمج α=0.8	COCO (صورة 440)	0.680	0.666	-0.013	[-0.022, -0.005]	**لا: الفرق حقيقي**
v3 − دمج α=0.8	مسيّرة (300 صورة)	0.765	0.817	+0.052	[+0.032, +0.077]	**لا: الفرق حقيقي**

- **v3 مقابل v2: لا فرق مؤكد** (الفاصلان يحويان الصفر). فالفكرة 1 لم تُثبت تحسيناً. الفرق على COCO (+0.020) على الحافة فقط.
- **الدمج (α = 0.8) مقابل v3: الفرقان حقيقيان** (الفاصلان لا يحويان الصفر): كسبنا 0.013 على COCO وخسرنا 0.052 على المسيّرة. أي أن كل 0.013 نكسبها على COCO تكلّفنا نحو 0.05 على المسيّرة.
- حجم الضجيج في هذه القياسات حوالي ±0.02 (نصف عرض الفاصل). الفروق الأصغر منه لا يُعتدّ بها.

حدود هذا القياس

البوتستراب يعيد اختيار **صور الاختبار** فقط. لا يعكس تذبذب التدريب نفسه (لو أعدنا التدريب بـ seed آخر لتغيّرت الأرقام أيضاً)، فالضجيج الحقيقي أكبر من المقدَّر هنا.

6. التوصية

إن كنتَ تريد	استعمل	لماذا
النموذج الافتراضي: كل الفئات الـ 12 بتوازن	`models/v3_yolo11n_12cls.pt`	أعلى متوسط على الاختبار (0.742)، وهو غير مختلف إحصائياً عن v2 (الفصل 5). اخترتُه لأن رقمه أعلى قليلاً لا لأنه أفضل بيقين.
فئات COCO فقط، بأعلى دقة	YOLO11n الجاهز	0.718 مقابل 0.666. لا يعرف المسيّرة.
COCO أفضل قليلاً مع مسيّرة أضعف	دمج $\alpha = 0.6$ أو 0.8 (`interpolate_models.py`)	$\alpha = 0.8$: COCO 0.680 والمسيّرة 0.765. المقايضة غير مجزية لمعظم الاستعمالات، لذلك لم أضعه في المستودع.

7. ما قد يحسّن الرقم فعلاً (لم نجرّبه)

بعد ثلاث محاولات (v2، v3، الدمج) وصلنا إلى حدّ لا نستطيع تجاوزه بتغييرات صغيرة على هذا الجهاز. الخيارات أدناه تقديرات، وليست نتائج:

الخيار	الفكرة	الكلفة التقريبية	هل يحل المشكلة؟
بيانات COCO أكثر (آلاف الصور لكل فئة)	أقل نسياناً	ساعات كثيرة على CPU. GPU تجعلها دقائق	على الأرجح يقلّص الفجوة
نموذج أكبر (YOLO11s)	سعة أكبر	أبطأ نحو 3 مرات (تقدير من عدد العمليات في الشبكة، لم أقِسه)	يرفع الجميع، وقد لا يزيل الفجوة
جمع نموذجين: الجاهز لـ COCO + كاشف مسيّرات	لا نسيان، كل فئة بأفضل نموذج لها	ضعف زمن الاستدلال تقريباً (حوالي 77 + 56 مللي ثانية)	يحقق الدقتين، لكنه **ليس ملفاً واحداً**، وهذا كان طلب الأستاذ
تجميد الجزء الأول من الشبكة أثناء الضبط	الخصائص الأساسية لا تتغير	أسرع من الضبط الكامل	غير معروف، قد لا يتجاوز الضجيج
التقطير (Distillation) من الجاهز أثناء الضبط	خسارة إضافية تُبقي الفئات القديمة قريبة من الجاهز	كود مخصص في المدرّب	الفكرة الأقرب لحل النسيان، ولم أنفّذها

8. تحفظات وأسئلة

تحفظات

- تدريب واحد لكل نموذج (seed واحد). الضجيج الحقيقي أكبر من المقدَّر بالبوتستراب.
- الدمج جُرّب على زوج نماذج واحد فقط.
- مجموعتا الضبط والاختبار صغيرتان (197/440 صورة COCO، و150/300 مسيّرة). قد تتشابه صور المسيّرات بين الأقسام (لقطات متتابعة)، فأرقامها متفائلة للنماذج كلها.
- السرعة قيست على CPU بأربعة أنوية.
- لم أفصل أثر صف kite عن أثر معدل التعلم الأقل وعدد الجولات الأقل. الفكرة 1 غُيّرت فيها ثلاثة أشياء معاً.

أسئلة للمراجعة

1. ما الخطأ الذي كنتُ فيه عن الطبقة الأخيرة، وكيف اكتُشف؟

ظننتُ أن التدريب الأول بدأ بطبقة تصنيف عشوائية. سجل التدريب الفعلي فيه سطر "Remapped 11/12 cls head rows by class name": المكتبة تنسخ الصفوف المتطابقة تلقائياً. اختباري تجاوز هذه الخطوة.

2. لماذا اخترنا α على مجموعة ضبط منفصلة؟

لو اخترناه على الاختبار لكانت النتيجة المعلنة متفائلة، لأن القيمة اختيرت لأنها تبدو جيدة على تلك الصور بعينها.

3. ماذا حدث لمكسب الدمج الذي ظهر على مجموعة الضبط؟

اختفى على الاختبار. مجموعة الضبط صغيرة، فقفزة 0.03 كانت ضجيجاً.

4. ماذا يعني أن فاصل الثقة 95% للفرق يحوي الصفر؟

أن الفرق قد يكون ناتجاً عن حظّ اختيار الصور، فلا نستطيع القول إن أحد النموذجين أفضل.

5. لماذا يمكن أن يعمل متوسط الأوزان أصلاً؟

لأن النموذج المضبوط بمعدل تعلم صغير يبقى قريباً من نقطة بدايته، فالنقاط على الخط بينهما تبقى في نفس "الوادي" ولا تنهار. (في تجربتنا أعطت مقايضة سلسة.)

6. لماذا لا نضع ملفين في ملف واحد لنحصل على أفضل ما في الاثنين؟

يمكن تشغيل نموذجين معاً ودمج النتائج، لكنه ليس ملف .pt واحداً، ويضاعف زمن الاستدلال.